

Anomaly Detection in biomedical data by means of Autoencoders

Matías Cisnero¹ and Juliana Gambini^{1,2} 

¹ LIDEC, Universidad Nacional de Hurlingham, Pcia. de Buenos Aires, Argentina
juliana.gambini@unahur.edu.ar

² CPSI, Universidad Tecnológica Nacional, Regional Buenos Aires

Abstract. This line of research addresses the detection of anomalies in biomedical data using the Autoencoder method.

Autoencoders are artificial neural networks with a symmetrical architecture in which the input layer is the same as output layer. This method reduces the dimension of original data and then reconstructs it. The reconstruction error is the key point of this research.

The hypothesis of this work is that patients who present a large reconstruction error (greater than a threshold) can be classified as anomalous, which can help the medical professional to detect diseases.

With this objective, the Autoencoder method is implemented and trained with different proportions of data from healthy and sick patients. Several architectures are used to optimize the parameters.

Three variants are evaluated: the classic autoencoder, the sparse autoencoder, and the contractive autoencoder. The threshold used to classify these data as normal or anomalies based on their reconstruction error is computed using the Youden index.

In this case, the methods are tested using the Breast Cancer Wisconsin (Diagnostic) dataset, which has samples from patients with benign and malignant patterns obtained by fine-needle aspiration (FNA).

The results are encouraging, but further research is needed to obtain more conclusive results.

Keywords: anomaly detection, biomedical data, autoencoders

Detección de Anomalías en datos biomédicos utilizando Autoencoders

Abstract. La presente línea de investigación aborda la detección de anomalías en datos biomédicos utilizando el método Autoencoder.

Los Autoencoders son redes neuronales artificiales que poseen una arquitectura simétrica, en la que la capa de entrada es exactamente igual a la de salida. Este método reduce la dimensión de los datos originales para

luego reconstruirlos. El error de reconstrucción es la pieza clave de esta investigación.

La hipótesis de este trabajo es que los pacientes que presenten un error de reconstrucción grande (mayor que un umbral), pueden ser clasificados como anómalos, lo cual puede ayudar al profesional médico a detectar enfermedades.

Con este objetivo, se implementa el método Autoencoder y se entrena con distintas proporciones de datos de pacientes sanos y enfermos. Se utilizan diferentes arquitecturas para optimizar los parámetros.

Se evalúan tres variantes: el autoencoder clásico, el *sparse* autoencoder y el *contractive* autoencoder. El umbral utilizado para clasificar estos datos como normales o anomalías según su error de reconstrucción, se calcula utilizando el índice de Youden.

En este caso, los métodos se prueban utilizando el conjunto de datos Breast Cancer Wisconsin (Diagnostic), que posee muestras de pacientes con patrones benignos y malignos obtenidas mediante punción con aguja fina (FNA).

Los resultados son alentadores pero es necesario profundizar la investigación para obtener resultados más contundentes.

Keywords: detección de anomalías, datos biomédicos, autoencoders

1 Introducción

Motivación El diagnóstico temprano de enfermedades como el cáncer de mama es una tarea prioritaria en la medicina moderna y el análisis de datos puede permitir detectar patrones que colaboren con el personal de salud en el diagnóstico preciso de algunas enfermedades.

El método de redes neuronales utiliza aprendizaje supervisado y permite detectar patrones que pueden pasar desapercibidos cuando se utilizan otros métodos de aprendizaje automático.

Los Autoencoders son un tipo de redes neuronales, que constituyen un buen candidato para esta tarea porque están diseñados para aprender representaciones compactas con las características más relevantes de los datos, permitiendo distinguir entre anomalías y datos normales.

Hipótesis Este trabajo se basa en la hipótesis de que al entrenar el Autoencoder únicamente con datos normales, los registros anómalos (malignos) tendrán un mayor error de reconstrucción $\|\hat{t} - t\|$ en comparación con los normales (benignos). Para decidir cuál es mínimo error de reconstrucción para el cual se decide que los datos provienen de una anomalía es necesario utilizar un umbral. Este umbral de decisión se calcula con el índice de Youden.

Estado del arte Se desarrollaron múltiples variantes de los Autoencoders, evaluadas por los autores Neloy y Turgeon. Los cuales comparan la capacidad de reconstrucción, generación de muestras, visualización del espacio latente y precisión en clasificación de datos anómalos en 11 arquitecturas. Demostrando una mayor capacidad para detección de anomalías los modelos IWAE, β -VAE y adVAE.

Otras propuestas como la de Nawaz et al. incluyen a los *Ensemble of Autoencoders* como alternativa más robusta al uso de un solo modelo.

2 Materiales y Métodos

2.1 Conjunto de datos

Para la realización de este trabajo, se utiliza el conjunto de datos *Breast Cancer Wisconsin (Diagnostic) Data Set*. El cual está compuesto por 569 registros de muestras citológicas con 357 de estas etiquetadas como benignas (B) y 212 como malignas (M), los atributos corresponden a características numéricas derivadas del análisis de imágenes digitalizadas obtenidas mediante FNA.

Para analizar la robustez del Autoencoder frente a distintos niveles de contaminación en los datos, se realiza una división del conjunto en entrenamiento (60%), validación (20%) y prueba (20%).

A partir del subconjunto de entrenamiento, se generan tres nuevos subconjuntos de igual tamaño con distintas proporciones de anomalías: A con 0%, B con 10% y C con 25%.

Todos los subconjuntos se estandarizan utilizando la media y el desvío estándar del subconjunto de entrenamiento.

2.2 Descripción de los métodos

Autoencoders El método empleado en este trabajo es el Autoencoder, un tipo de perceptrón multicapa caracterizado por su estructura simétrica respecto a la capa latente y por poseer la misma dimensión tanto en la entrada como en la salida.

La arquitectura de un Autoencoder se compone de dos partes principales: el *encoder*, que transforma los datos de entrada en una representación de menor dimensionalidad, y el *decoder*, que intenta reconstruir la entrada original a partir de dicha representación compacta.

También se utilizan dos variantes del Autoencoder, el *Sparse Autoencoder (SAE)* y *Contractive Autoencoder (CAE)*, los cuales imponen restricciones adicionales sobre la capa latente.

Métricas de evaluación Para evaluar el desempeño del autocodificador en la tarea de detección de anomalías, se analizan métricas derivadas del error de reconstrucción $\|\hat{t} - t\|$. Este valor se utiliza como criterio de decisión para

distinguir entre casos normales y anómalos mediante un umbral ϵ , calculado con el índice de Youden. El registro se considera anomalía si lo supera.

$$\hat{y} = \begin{cases} 0, & \text{si } \|\hat{t} - t\| \leq \epsilon \\ 1, & \text{si } \|\hat{t} - t\| > \epsilon \end{cases} \quad (1)$$

A partir de esta regla se construye la matriz de confusión, y se calculan las métricas de exactitud, sensibilidad y especificidad, entre otras. Asimismo, se emplean la curva ROC y el área bajo dicha curva (AUC) para caracterizar el rendimiento del modelo sin depender de un valor de umbral fijo.

3 Resultados

Las configuraciones de cada modelo surgen de un proceso de *grid search*. Obteniendo los hiperparámetros de la Tabla 1.

Table 1. Hiperparámetros de entrenamiento para cada modelo.

Modelo	Dimensiones de capas	lr	Batch size	Épocas
AE	[30, 32, 16, 8, 4, 2]	0.001	16	200
SAE	[30, 64]	0.001	16	200
CAE	[30, 32, 16]	0.001	16	200

Los resultados se visualizan en la Tabla 2. Donde se observa que el mayor *Recall* lo posee el modelo **CAE (A)** y el modelo **SAE (A)** cuenta con el mayor *F1_{score}*, *Precision* y *Specificity*. También se visualiza el decrecimiento de las métricas al aumentar las anomalías en el entrenamiento de los modelos, mayormente en el modelo SAE.

Table 2. Métricas para cada modelo entrenado con los subconjuntos A, B y C.

Modelo	Accuracy	Precision	Recall	Specificity	Balanced Accuracy	<i>F1_{score}</i>
AE (A)	0.860	0.771	0.881	0.847	0.864	0.822
AE (B)	0.746	0.618	0.810	0.708	0.759	0.701
AE (C)	0.632	0.500	0.619	0.639	0.629	0.553
SAE (A)	0.939	0.973	0.857	0.986	0.922	0.911
SAE (B)	0.754	0.652	0.714	0.778	0.746	0.682
SAE (C)	0.640	0.538	0.167	0.917	0.542	0.255
CAE (A)	0.930	0.886	0.929	0.931	0.930	0.907
CAE (B)	0.798	0.757	0.667	0.875	0.771	0.709
CAE (C)	0.693	0.566	0.714	0.681	0.697	0.632

4 Conclusiones y trabajos futuros

Los resultados experimentales muestran una buena capacidad discriminativa de los modelos, destacando por sus métricas generales al SAE y por su *Recall* junto a su robustez ante la presencia de anomalías al CAE. Por otra parte, el autoencoder clásico presenta un resultado aceptable en las métricas, teniendo mayor robustez al ruido que el SAE pero sin destacar en ninguna métrica.

Aunque los resultados alcanzados son satisfactorios, quedan abiertas múltiples líneas de investigación, como la aplicación de nuevos enfoques para la detección de anomalías o el estudio en distintos tipos de datos (como imágenes o series de tiempo), siguiendo las bases planteadas en este trabajo.