

Detección de Anomalías Utilizando Autocodificadores

Autor: Matías Cisnero

Tutora: Dra. M. Juliana Gambini

Diciembre 2025 Universidad Nacional de Hurlingham



- 1 Introducción
- 2 Conjunto de datos
- 3 Autocodificadores para detección de anomalías
- 4 Resultados
- 5 Conclusiones

Introducción



La **detección de anomalías** es un campo fundamental dentro del análisis de datos, cuyo objetivo principal es la identificación de patrones que no se ajustan a un comportamiento que coincide con el de la mayoría de los registros.

En el contexto de los datos de salud, una anomalía puede representar un error de medición, o una indicación temprana de una condición médica patológica, como el cáncer de mama.



Con la motivación de facilitar la detección de enfermedades como el **cáncer de mama**, se considera que:

- Los casos **benignos** generan datos médicos que siguen cierta distribución esperada.
- Los casos **maligos** generan registros atípicos respecto a esa distribución.

Esta idea guía el diseño de un **autocodificador** que aprenda la distribución de datos benignos y permita detectar desviaciones respecto a su distribución.

Este tipo de modelos podría asistir a profesionales de la salud en la detección temprana de pacientes en riesgo. Utilizando el método como una herramienta y no como un intento de reemplazo del profesional.

Conjunto de datos:

Obtención, atributos y distribución.



Se utiliza el conjunto de datos *Breast Cancer Wisconsin (Diagnostic) Data Set*, el cual se obtuvo de la plataforma Kaggle [3], que es una copia del dataset original publicado por Wolberg et al. [7].

El conjunto de datos está compuesto por **569 registros** de muestras citológicas y **32 atributos**, de los cuales:

- 30 corresponden a características numéricas derivadas del análisis de imágenes digitalizadas, correspondientes a aspiraciones con aguja fina de masas mamarias.
- Las 2 características restantes son categóricas, *ID*, el cual es solo un metadato que no se utiliza para el entrenamiento del modelo y el **diagnóstico** que puede ser benigno o maligno.

Las muestras incluidas en el conjunto de datos fueron recolectadas entre enero de 1989 y noviembre de 1991.



Las **muestras citológicas** se refieren a grupos celulares obtenidas de las masas mamarias mediante la técnica de aspiración con aguja fina (FNA), que es un procedimiento poco invasivo utilizado para obtener material celular mediante la punción de la masa mamaria con una aguja de pequeño calibre, tal como se observa en la Figura 1.




Figura 1: Proceso de FNA (tomado de [2])



Los atributos numéricos del conjunto de datos describen propiedades morfológicas de los núcleos celulares extraídas a partir de las imágenes digitalizadas de las muestras citológicas. Estas características, definidas en el trabajo original de Street et al. [6], capturan información relacionada con el tamaño, la forma, la textura y la simetría de las células, aspectos relevantes para la diferenciación entre casos benignos y malignos.

A partir de diez características base, se calculan tres medidas estadísticas para cada una: la **media**, el **error estándar** y el **peor valor**, definido como la media de los tres valores más grandes de la característica. De este modo, se obtienen los **30 atributos numéricos** utilizados.



Analizando el conjunto de datos se observan las cantidades de casos benignos y malignos con las que se cuentan. Esto se visualiza en la Tabla 1.

Cuadro 1: Distribución de la variable objetivo *diagnosis*

Valor	Porcentaje (%)	Cantidad de registros
B (Benigno)	62.74	357
M (Maligno)	37.26	212

División del conjunto (1)



Para realizar el entrenamiento del modelo se divide el conjunto de datos en 3 subconjuntos: entrenamiento, validación y prueba. Tal como se muestra en el paso **(1)** de la Figura 2.

- Entrenamiento: se utiliza para entrenar al modelo.
- Validación: su función es evitar un sobreajuste (*overfitting*) en el modelo.
- Prueba: sirve para realizar las evaluaciones finales del modelo.




Figura 2: Esquema de la división del conjunto de datos.



Cada uno de los subconjuntos utilizados, ya sean de entrenamiento, validación o prueba, se encuentran estandarizados. Este método transforma las variables para que tengan una media (μ) de cero y una desviación estándar (σ) de uno, asegurando que todas las entradas del modelo tengan una escala comparable. Este proceso se define formalmente en la Ecuación 1.

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

donde x corresponde al dato original y tanto μ como σ , a la media y la desviación estándar de esa variable, respectivamente.

La estandarización también contribuye a mitigar posibles problemas de *overflow* en las activaciones del autocodificador, los cuales pueden surgir cuando el modelo recibe valores excesivamente grandes.

División del conjunto (2)



Luego, con el objetivo de evaluar la robustez del autocodificador al tener presentes anomalías durante el entrenamiento, se construyen los subconjuntos de entrenamiento **A**, **B** y **C**.

Esta división se visualiza como el paso **(2)** de la Figura 2. Los valores se presentan en la Tabla 2.

ID	Anómalos (%)	Normales (%)	Cant. Anómalos	Cant. Normales
A	0 %	100 %	0	214
B	10 %	90 %	21	193
C	25 %	75 %	53	161

Cuadro 2: Subconjuntos derivados del subconjunto de entrenamiento para evaluar la resistencia del autocodificador ante diferentes proporciones de anomalías.


Autocodificadores para detección de anomalías:

Fundamentos y aplicación.

¿Qué es un autocodificador?



- Un **autocodificador** (*autoencoder*) es un tipo de perceptrón multicapa.
- Su característica principal es que la dimensión de la entrada es igual que la de salida (tamaño D).
- La red tiene una arquitectura simétrica con una o más capas ocultas (en número impar), con una capa central denominada **capa latente**.
- Generalmente, la capa latente tiene dimensión K , con $K < D$, lo que implica una **compresión** de la información.





El autocodificador tiene dos partes principales:

- **Codificador (Encoder):**
transforma la entrada $x^{(u)} \in \mathbb{R}^D$
en la representación comprimida
 $z^{(u)} \in \mathbb{R}^K$ en la capa latente.

- **Decodificador (Decoder):**
reconstruye la entrada a partir de
la representación latente $z^{(u)}$,
obteniendo la reconstrucción $\hat{x}^{(u)}$.





Figura 3: Ejemplo de un autocodificador, donde se codifica y decodifica una imagen (tomado de [1]).



Si bien el autocodificador clásico permite reducir la dimensionalidad, generando así una compresión de los datos; existen variantes que imponen restricciones adicionales sobre la representación latente, para evitar que el modelo aprenda la función identidad y forzar la extracción de características más robustas.





Sparse Autoencoder (SAE)

Impone una restricción de **dispersión** en la capa latente, forzando a que la mayoría de las neuronas permanezcan inactivas para cada entrada, lo que favorece la extracción de características más discriminativas.

Contractive Autoencoder (CAE)

Impone una restricción **contractiva** sobre la función de codificación, haciendo que la representación latente sea robusta frente a pequeñas perturbaciones en la entrada.



La detección de anomalías con autocodificadores se basa en el **error de reconstrucción** de la entrada. Un modelo entrenado únicamente con datos normales aprende su distribución y es capaz de reconstruirlos con bajo error.




Figura 4: Reconstrucción de una entrada normal. El error de reconstrucción es bajo y cumple $\|\hat{x}^{(u)} - x^{(u)}\| < \epsilon$.



En cambio, cuando la entrada corresponde a un dato atípico, el autocodificador no logra reconstruirla correctamente, produciendo un error elevado.




Figura 5: Reconstrucción de una entrada anómala. El error de reconstrucción es alto y cumple $\|\hat{t}^{(u)} - t^{(u)}\| > \epsilon$.

De este modo, el **error de reconstrucción** puede utilizarse como una métrica para la detección de anomalías, comparándolo con un umbral ϵ definido previamente.

Resultados



Para el entrenamiento de los modelos se definieron sus configuraciones mediante un proceso de *grid search*, en el cual se seleccionaron aquellas combinaciones que presentaron mejor desempeño en el conjunto de **validación**, priorizando las métricas de *Recall*, $F1_{score}$ y AUC.

Cuadro 3: Arquitecturas finales utilizadas en cada modelo.

Modelo	Dimensiones de capas
AE	[30, 32, 16, 8, 4, 2]
SAE	[30, 64]
CAE	[30, 32, 16]

Todos los modelos fueron entrenados utilizando **MSE** como función de pérdida y el optimizador **Adam**, con una tasa de aprendizaje $lr = 0,001$, un **batch size** de 16 y *early stopping* con una paciencia de 20 épocas, hasta un máximo de 200 épocas.

A continuación se muestran los errores de reconstrucción obtenidos con el autocodificador clásico en los conjuntos de datos A, B y C.

En los histogramas se pueden observar donde se posicionan los distintos umbrales en la clasificación.





Figura 6: Distribución del error de reconstrucción para el autocodificador A.






Figura 8: Distribución del error de reconstrucción para el autocodificador C.



Con los umbrales y errores de reconstrucción computados, se realizan las clasificaciones para calcular los valores de la matriz de confusión y con ellos las métricas.

En todos los casos se utiliza el umbral calculado a partir del **Índice de Youden**, debido a su capacidad para maximizar las métricas de *Recall* y *Specificity*.

Se calculan las métricas para cada modelo entrenado con los subconjuntos A, B y C.

Cuadro 4: Métricas de rendimiento para cada modelo entrenado con los subconjuntos A, B y C.

Modelo	Accuracy	Precision	Recall	Specificity	Balanced Accuracy	F1 _{score}
AE (A)	0.860	0.771	0.881	0.847	0.864	0.822
AE (B)	0.746	0.618	0.810	0.708	0.759	0.701
AE (C)	0.632	0.500	0.619	0.639	0.629	0.553
SAE (A)	0.939	0.973	0.857	0.986	0.922	0.911
SAE (B)	0.754	0.652	0.714	0.778	0.746	0.682
SAE (C)	0.640	0.538	0.167	0.917	0.542	0.255
CAE (A)	0.930	0.886	0.929	0.931	0.930	0.907
CAE (B)	0.798	0.757	0.667	0.875	0.771	0.709
CAE (C)	0.693	0.566	0.714	0.681	0.697	0.632



Se observa un buen rendimiento general para los modelos entrenados con el conjunto A (0 % de anomalías). Destaca el modelo **SAE (A)** por sus buenas métricas generales y el modelo **CAE (A)** por su alto valor de *Recall*.

También se visualiza como bajan los valores de las métricas a medida que aumenta el porcentaje de anomalías en el entrenamiento. Aunque el modelo **CAE** demuestra mayor robustez ante este hecho.



El valor de *Recall* de 0.929 del modelo **CAE (A)** indica que el 92.9 % de los pacientes con tumores malignos es clasificado correctamente como anómalo, lo que implica una baja proporción de falsos negativos.

En problemas de detección de anomalías aplicados al ámbito médico, un alto valor de *Recall* resulta especialmente relevante, ya que minimizar los falsos negativos reduce el riesgo de no detectar casos patológicos que requieren atención clínica.



A continuación se presentan los gráficos de las curvas ROC para todos los modelos, agrupando las curvas según el conjunto de entrenamiento. Esto con el fin de comparar la robustez de cada modelo a la contaminación de los datos.

La curva ROC y el AUC permiten evaluar la capacidad discriminativa de los modelos independientemente del umbral ϵ utilizado.




Figura 9: Curvas ROC y AUC obtenidos para los modelos AE, SAE y CAE entrenados con el Conjunto A (0% de anomalías).




Figura 10: Curvas ROC y AUC obtenidos para los modelos AE, SAE y CAE entrenados con el Conjunto B (10 % de anomalías).




Figura 11: Curvas ROC y AUC obtenidos para los modelos AE, SAE y CAE entrenados con el Conjunto C (25 % de anomalías).

Conclusiones



Los resultados experimentales muestran una buena capacidad discriminativa de los modelos, destacando por sus métricas generales al SAE y por su *Recall* junto a su robustez ante la presencia de anomalías al CAE. Por otra parte, el autocodificador clásico presenta un resultado aceptable en las métricas, teniendo mayor robustez al ruido que el SAE pero sin destacar en ninguna métrica.



Si bien los modelos evaluados presentan resultados satisfactorios, hay que tener en cuenta que las características de las muestras del conjunto de datos corresponden a pacientes de los hospitales y clínicas de la universidad de Wisconsin, estado de EE.UU.

El modelo puede no funcionar satisfactoriamente en pacientes no pertenecientes a esa población. Es decir, tiene un sesgo correspondiente a la región.



El Proyecto Integrador está disponibles en el siguiente repositorio de Github:

<https://github.com/matias-cisnero/anomaly-detection-with-autoencoder>



Dor Bank, Noam Koenigstein, and Raja Giryes.

Autoencoders.

arXiv preprint arXiv:2003.05991, 2020.



Cleveland Clinic.

Fine-needle aspiration (fna), 2023.

Accedido: 2025-12-14.



UCI Machine Learning and Ovsen.

Breast cancer wisconsin (diagnostic) data set.

<https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data>.

Kaggle Dataset. Accedido: 2025-11-27.



Andrew Ng et al.

Sparse autoencoder.

CS294A Lecture notes, 72(2011):1–19, 2011.



Salah Rifai, Pascal Vincent, Xavier Muller, Xavier Glorot, and Yoshua Bengio.

Contracting auto-encoders.

In Proceedings of the International Conference on Machine Learning (ICML), Bellevue, WA, USA, page 95, 2011.



William Nick Street, William H. Wolberg, and Olvi L. Mangasarian.

Nuclear feature extraction for breast tumor diagnosis.

In Electronic imaging, 1993.



William Wolberg, Olvi Mangasarian, Nick Street, and W. Street.

Breast cancer wisconsin (diagnostic).

UCI Machine Learning Repository, 1993.


DOI: <https://doi.org/10.24432/C5DW2B>.

¡Gracias!



Apéndice

AED: Matriz de Correlación




Observaciones

- Se observan fuertes correlaciones lineales entre atributos geométricos relacionados (Área, Perímetro, Radio).
- Relaciones inversas leves entre medidas de tamaño y la dimensión fractal.



Comparación de distribuciones entre clases (Benigno/Maligno).



El **Área Media** presenta la distinción más clara, mientras que la **Dimensión Fractal** muestra una gran superposición.




GELU (Gaussian Error Linear Unit):

$$\text{GELU}(x) = 0,5x(1+\tanh(\sqrt{2/\pi}(x+0,044715)))$$

Ventajas sobre ReLU

- Es suave cerca de 0.
- Evita el problema de las "neuronas muertas".
- Formulación probabilística.





El SAE añade un término de penalización basado en la **Divergencia Kullback-Leibler (KL)** para forzar la inactividad de las neuronas.

Función de Pérdida

$$\mathcal{L}_{\text{sparse}} = \underbrace{\text{MSE}(X, \hat{X})}_{\text{Reconstrucción}} + \beta \sum_{j=1}^H \text{KL}(\rho \parallel \hat{\rho}_j)$$

Donde la divergencia KL se define como:

$$\text{KL}(\rho \parallel \hat{\rho}_j) = \rho \log \frac{\rho}{\hat{\rho}_j} + (1 - \rho) \log \frac{1 - \rho}{1 - \hat{\rho}_j}$$

- ρ : Parámetro de dispersión deseado (ej. 0.05).
- $\hat{\rho}_j$: Activación promedio real de la neurona j .



Para el término de dispersión (KL) en el SAE, es necesario calcular la activación promedio real de cada neurona oculta j sobre el conjunto de datos (o un *batch*).

Activación Promedio

$$\hat{\rho}_j = \frac{1}{N} \sum_{u=1}^N a_j^{(u)}$$

Donde N es el número de ejemplos y $a_j^{(u)}$ es la activación de la neurona j para el ejemplo $x^{(u)}$, dada por la función de activación aplicada a la suma ponderada de entradas y sesgo:

$$a_j^{(u)} = g \left(\sum_{k=1}^D w_{jk} x_k^{(u)} \right)$$



El CAE penaliza la sensibilidad del codificador a pequeñas variaciones en la entrada utilizando la norma de Frobenius de la matriz Jacobiana.

Función de Pérdida

$$\mathcal{L}_{\text{CAE}} = \underbrace{\text{MSE}(X, \hat{X})}_{\text{Reconstrucción}} + \lambda \sum_{u=1}^N \|J_f(x^{(u)})\|_F^2$$

- $J_f(x^{(u)})$: Jacobiano de la función de codificación.
- Esto fuerza al modelo a aprender un mapeo suave (contractivo), ignorando variaciones irrelevantes (ruido).



El conjunto consta de **30 atributos numéricos**. Estos se derivan de 10 características base calculadas a partir de las imágenes digitalizadas de FNA.

No.	Característica	Descripción
1	Radio	Media de distancias centro-perímetro.
2	Textura	Desviación estándar de escala de grises.
3	Perímetro	Medida del contorno del núcleo.
4	Área	Superficie del núcleo.
5	Suavidad	Variación local en longitudes del radio.
6	Compacidad	$\text{Perímetro}^2 / \text{área} - 1,0$.
7	Concavidad	Severidad de las porciones cóncavas.
8	Puntos Cóncavos	Número de porciones cóncavas.
9	Simetría	Nivel de simetría del núcleo.
10	Dimensión Fractal	Aproximación a la "línea de costa 1.

Para cada una de estas 10 características, se calculan 3 medidas: **Media** (Mean), **Error Estándar** (SE) y **Peor Valor** (Worst), resultando en los 30 atributos totales.



Se evaluaron distintos métodos para definir el umbral de corte ϵ . Se seleccionó el **Índice de Youden** por maximizar conjuntamente *Recall* y *Specificity*.

Modelo	Media + 2σ	Percentil 95	Youden (Elegido)
AE (A)	0.665	0.657	0.446
SAE (A)	0.356	0.334	0.762
CAE (A)	0.095	0.052	0.037

- **Media/Percentil:** Dependen solo de la distribución de los datos normales.
- **Youden:** Optimiza el punto de corte en la curva ROC
($J = \text{Sensibilidad} + \text{Especificidad} - 1$).