

Detección de Anomalías Utilizando Autocodificadores

Autor: Matías Cisnero

Tutor: Dra. M. Juliana Gambini

Diciembre 2025

Universidad Nacional de Hurlingham



Índice General

1	Introducción	11
1.1	Motivación	11
1.2	Estado del Arte	11
1.2.1	Autoencoders for Anomaly Detection Are Unreliable	12
1.2.2	A comprehensive study of auto-encoders for anomaly detection	12
1.2.3	Enhancing Anomaly Detection Through Latent Space Manipulation	12
1.2.4	Ensemble of Autoencoders for Anomaly Detection in Biomedical Data	12
2	Materiales y Métodos	13
2.1	Conjunto de datos y análisis exploratorio	13
2.2	Descripción de los métodos	16
2.2.1	Autocodificadores	16
2.2.2	Métricas de evaluación del modelo	18
3	Resultados	21
4	Conclusiones	25

Índice de Figuras

2.1	Matriz de correlación entre los atributos del conjunto de datos.	15
2.2	Diagrama del proceso de división del dataset en entrenamiento y prueba, y posterior creación de los conjuntos A, B y C con diferentes proporciones de anomalías.	16
2.3	Arquitectura de un autocodificador: la entrada X es procesada por el codificador hasta obtener la representación latente Z , a partir de la cual el decodificador reconstruye la salida Y	17
2.4	Comparación entre las funciones de activación ReLU y GELU. Se observa que GELU presenta una transición suave alrededor de cero, lo que evita discontinuidades y favorece un entrenamiento más estable en modelos neuronales.	18
3.1	Arquitectura del autocodificador utilizado	21
3.2	Distribución del error de reconstrucción para el Modelo A.	22
3.3	Distribución del error de reconstrucción para el Modelo B.	23
3.4	Distribución del error de reconstrucción para el Modelo C.	23
3.5	Matriz de confusión expresada en valores porcentuales para el conjunto evaluado.	23

Índice de Tablas

2.1	Descripción de las diez características base del conjunto de datos.	14
2.2	Distribución de la variable objetivo <i>diagnosis</i>	14
2.3	Conjuntos de entrenamiento creados para evaluar la resistencia del autocodificador ante diferentes proporciones de anomalías.	16
2.4	Matriz de confusión. La diagonal verde representa predicciones correctas, mientras que las celdas rojas corresponden a errores de clasificación.	19
3.1	Hiperparámetros de entrenamiento empleados para los modelos A, B y C, entrenados con los correspondientes conjuntos.	22
3.2	Valores de umbral ϵ obtenidos para los modelos A, B y C.	22
3.3	Métricas de rendimiento del modelo evaluado sobre el mismo conjunto de prueba para los conjuntos A, B y C. Cada conjunto fue entrenado con distinta proporción de datos anómalos, lo que permite analizar la robustez del autocodificador frente a diferentes niveles de contaminación en el entrenamiento.	24

Resumen

El presente trabajo (o informe) aborda el problema de la detección de anomalías en conjuntos de datos de salud, enfocándose en el diagnóstico temprano y la prevención de enfermedades como la diabetes. Se emplea la arquitectura de Autocodificadores (*Autoencoders*), una clase de red neuronal no supervisada, para aprender una representación compacta y eficiente de los patrones de datos normales. El modelo se entrena utilizando el conjunto de datos **Diabetes Health Indicators Dataset**, donde se considera anómalo cualquier patrón que se desvíe significativamente de la reconstrucción esperada. La implementación se realiza mediante la biblioteca PyTorch. Los resultados de esta investigación muestran ***. Se presenta un análisis exploratorio de los datos inicial, incluyendo la matriz de correlación y ***.

Chapter 1

Introducción

Describir el problema que se desea resolver

La detección de anomalías es un campo fundamental dentro del análisis de datos, cuyo objetivo principal es la identificación de patrones que no se ajustan a un comportamiento que coincide con el de la mayoría de los registros. En el contexto de los datos de salud, una anomalía puede representar un error de medición, o una indicación temprana de una condición médica patológica, como la diabetes. Este trabajo se centra en desarrollar un sistema robusto para la detección automática de tales desviaciones. Se busca resolver la limitación de los métodos estadísticos tradicionales, los cuales a menudo no logran capturar las complejas interrelaciones no lineales presentes en conjuntos de datos de alta dimensionalidad. El problema específico que se aborda es cómo entrenar un **autocodificador** para que aprenda exclusivamente el perfil de pacientes normales o sanos a partir de un conjunto de datos que solamente incluya pacientes sanos y otro con pacientes sanos y enfermos, y cómo utilizar su error de reconstrucción para señalar con precisión qué registros se consideran anómalos.

1.1 Motivación

Explicar porqué estudiamos este problema, para qué sirve, cuál es el impacto y en qué áreas.

El diagnóstico temprano de enfermedades como la diabetes es una tarea prioritaria en la medicina moderna. En muchos casos, los datos clínicos contienen patrones sutiles que pueden pasar desapercibidos a través de métodos tradicionales de análisis. Por este motivo, resulta fundamental el desarrollo de herramientas automáticas capaces de detectar irregularidades de manera precisa y rápida.

Las redes neuronales, y en particular los autocodificadores, ofrecen un enfoque adecuado para esta tarea. Un autocodificador es un tipo de red neuronal diseñado para aprender una representación comprimida de los datos, capturando sus características más relevantes. Esta capacidad lo convierte en un candidato natural para identificar desviaciones respecto del comportamiento considerado normal.

La incorporación de este tipo de modelos en sistemas de monitoreo podría asistir a profesionales de la salud en la detección temprana de pacientes en riesgo, incluso antes de la manifestación de síntomas clínicos evidentes. Por ello, en este proyecto se emplea un autocodificador como herramienta para analizar registros de pacientes y explorar su utilidad como detector de posibles anomalías asociadas a la diabetes.

1.2 Estado del Arte

En esta sección se realiza una descripción de algunos de los métodos más importantes existentes en la bibliografía describiendo el problema y el método utilizado por cada autor.

Se cita la bibliografía.

1.2.1 Autoencoders for Anomaly Detection Are Unreliable

Bouman y Heskes (2025) [1] analizan críticamente el uso de autocodificadores clásicos como detectores de anomalías. El trabajo sostiene que, bajo ciertas condiciones, los autocodificadores pueden reconstruir correctamente ejemplos anómalos, lo cual conduce a falsos negativos incluso en casos evidentes.

Metodología.

Resultados principales.

Limitaciones.

Relevancia.

1.2.2 A comprehensive study of auto-encoders for anomaly detection

Neloy y Turgeon (2024) [4]

1.2.3 Enhancing Anomaly Detection Through Latent Space Manipulation

Walczyna et al. (2025) [5]

1.2.4 Ensemble of Autoencoders for Anomaly Detection in Biomedical Data

<https://ieeexplore.ieee.org/abstract/document/10418130>

Chapter 2

Materiales y Métodos

Describir los métodos utilizados, si corresponde.

El método empleado en este proyecto es el **Autocodificador** (*Autoencoder*). Un autocodificador es un tipo de red neuronal artificial diseñada para aprender una representación codificada de un conjunto de datos de manera no supervisada. La arquitectura se compone de dos partes principales: el **Codificador** (*Encoder*) y el **Decodificador** (*Decoder*).

2.1 Conjunto de datos y análisis exploratorio

Se describen los datos utilizados y de donde fueron extraídos, si corresponde. En caso de que los datos sean propios, describir como fueron tomados

Para la realización de este trabajo, utilicé el conjunto de datos **Breast Cancer Wisconsin (Diagnostic) Data Set**, el cual obtuve de la plataforma Kaggle [3], que es una copia del dataset original publicado por Wolberg et al. [6].

El conjunto de datos está compuesto por 569 registros de muestras citológicas y 32 atributos, de los cuales 30 corresponden a características numéricas derivadas del análisis de imágenes digitalizadas de aspiraciones con aguja fina de masas mamarias. Estas características describen propiedades morfológicas de los núcleos celulares presentes en la imagen, tales como su tamaño, forma, textura y simetría.

La Aspiración con Aguja Fina (FNA, por sus siglas en inglés) es un procedimiento poco invasivo utilizado para obtener material celular mediante la punción de una lesión o masa con una aguja de pequeño calibre. Esta técnica, ampliamente empleada en el diagnóstico de tumores mamarios, permite recolectar células para su posterior análisis citológico, evitando métodos quirúrgicos más invasivos. Su uso en el estudio del cáncer de mama se remonta a la década de 1930 y ha demostrado poseer una elevada precisión diagnóstica cuando es ejecutada e interpretada por un patólogo especializado. Además, la FNA posibilita examinar características celulares y arquitectónicas del tejido aspirado, así como obtener material apto para tinciones citológicas que contribuyen a la detección de alteraciones malignas. Debido a su eficacia, simplicidad y bajo riesgo, la técnica se ha consolidado como una herramienta fundamental en la evaluación citológica de lesiones mamarias [2].

Los 30 atributos numéricos del conjunto de datos se derivan de diez características computadas para cada núcleo celular, las cuales se describen en la Tabla 2.1:

No.	Característica	Descripción
1	Radio (<i>radius</i>)	Media de las distancias del centro a los puntos del perímetro.
2	Textura (<i>texture</i>)	Desviación estándar de los valores de la escala de grises.
3	Perímetro (<i>perimeter</i>)	Medida del contorno del núcleo.
4	Área (<i>area</i>)	Superficie cubierta por el núcleo.
5	Suavidad (<i>smoothness</i>)	Variación local en las longitudes del radio.
6	Compacidad (<i>compactness</i>)	$\text{Perímetro}^2 / \text{área} - 1.0$.
7	Concavidad (<i>concavity</i>)	Severidad de las porciones cóncavas del contorno.
8	Puntos Cóncavos (<i>concave points</i>)	Número de porciones cóncavas del contorno.
9	Simetría (<i>symmetry</i>)	Nivel de simetría del núcleo celular.
10	Dimensión Fractal (<i>fractal dimension</i>)	Aproximación a la "línea de costa" menos 1.

Tabla 2.1: Descripción de las diez características base del conjunto de datos.

Para cada una de estas diez características se calculan tres medidas distintas, lo que completa los 30 atributos finales del conjunto de datos:

1. La **media** de la característica.
2. El **error estándar** (*Standard Error*, SE) de la característica.
3. El **'peor'** valor o más grande, el cual se calcula como la media de los tres valores más grandes de la característica.

Previo al entrenamiento del modelo, realicé un **análisis exploratorio de datos (EDA)** con el objetivo de comprender la estructura del conjunto de datos y detectar posibles problemas que afecten el desempeño del modelo. Este proceso incluyó la revisión de valores faltantes, la inspección de la distribución de cada variable y la generación de visualizaciones que permiten identificar patrones, tendencias y posibles anomalías.

Asimismo, apliqué una **estandarización** a los atributos no binarios con el fin de garantizar que todas las características se encuentren en una escala comparable, evitando que aquellas con valores numéricos más grandes dominen el proceso de entrenamiento.

Un componente central del EDA fue el análisis de la **matriz de correlación**, herramienta fundamental para evaluar las dependencias lineales entre los atributos. Esta matriz permite identificar relaciones fuertes entre variables, lo que facilita comprender la estructura interna del conjunto de datos y justifica la utilización de modelos capaces de capturar relaciones complejas y no lineales, como los autocodificadores utilizados en este trabajo.

Tras el análisis general de los atributos, se examinó la **distribución de la variable objetivo**, *diagnosis*, con el fin de comprender el balance entre las clases presentes en el conjunto de datos. La distribución se muestra en la Tabla 2.2.

Valor	Porcentaje (%)	Cantidad de registros
B (<i>Benigno</i>)	62.74	357
M (<i>Maligno</i>)	37.26	212

Tabla 2.2: Distribución de la variable objetivo *diagnosis*

Esta distribución revela un leve desbalance entre ambas categorías, algo esperable para este trabajo, donde se espera detectar una anomalía, es decir, un diagnóstico maligno.

Apliqué una estandarización a todos los atributos. La estandarización transforma las variables para que tengan una media (μ) de cero y una desviación estándar (σ) de uno, asegurando que todas las entradas al modelo tienen una escala comparable. Este proceso se define formalmente en la Ecuación 2.1.

$$z = \frac{x - \mu}{\sigma} \quad (2.1)$$

Donde x es el valor original del atributo, μ es su media y σ es su desviación estándar.

Calculé la matriz de correlación (ρ), la cual mide el grado de asociación lineal entre cada par de atributos del conjunto de datos. Su definición matemática se muestra en la Ecuación 2.2.

$$\rho(X, Y) = \frac{Cov(X, Y)}{s_x s_y} \quad (2.2)$$

Donde $Cov(X, Y)$ representa la covarianza entre X e Y , y s_x , s_y son sus desviaciones estándar. Finalmente, la covarianza utilizada en ese cálculo se expresa en la Ecuación 2.3.

$$Cov(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (2.3)$$

La matriz de correlación correspondiente a los principales indicadores de salud del conjunto de datos se presenta en la Figura 2.1, donde pueden observarse las relaciones lineales entre los distintos atributos.




Figura 2.1: Matriz de correlación entre los atributos del conjunto de datos.

Para analizar la robustez del autocodificador frente a distintos niveles de contaminación en los datos realicé una división del conjunto de datos en entrenamiento y prueba, manteniendo la proporción real de clases, tal como se indica en el paso (1) de la Figura 2.2. En esta etapa se reservó el 20% de las muestras para el conjunto de prueba, mientras que el 80% restante se destinó al entrenamiento.

A partir del subconjunto de entrenamiento, generé tres nuevos conjuntos con diferentes proporciones de anomalías, proceso señalado como paso (2) de la Figura 2.2. El objetivo fue evaluar cómo afecta al modelo entrenar con distintos niveles de contaminación controlada, manteniendo constante el tamaño total de cada conjunto (285 muestras).




Figura 2.2: Diagrama del proceso de división del dataset en entrenamiento y prueba, y posterior creación de los conjuntos A, B y C con diferentes proporciones de anomalías.

La Tabla 2.3 resume las proporciones definidas para cada conjunto de entrenamiento. El conjunto A contiene únicamente registros normales, mientras que B y C incorporan niveles crecientes de anomalías (10% y 25%, respectivamente).

ID	Proporción Anómalos (% Total)	Proporción Normales (% Total)	Registros Anómalos (Positivos)	Registros Normales (Negativos)
A	0%	100%	0	285
B	10%	90%	28	257
C	25%	75%	71	214

Tabla 2.3: Conjuntos de entrenamiento creados para evaluar la resistencia del autocodificador ante diferentes proporciones de anomalías.

2.2 Descripción de los métodos

Introducción...

2.2.1 Autocodificadores

El método empleado en este proyecto es un autocodificador, un tipo de perceptrón multicapa caracterizado por su estructura simétrica respecto a la capa latente y por tener la misma dimensión en la entrada (d) y en la salida. Aunque suele decirse que el aprendizaje en este modelo es no supervisado, en realidad sí es supervisado, ya que la salida esperada (Y) es la propia entrada (X).

En esta arquitectura, el **codificador** comprime la entrada en una representación ubicada en la **capa latente**, que es la capa oculta central y cuya dimensión (k) suele ser menor que la de la entrada ($k < d$). Esta capa contiene la representación comprimida de los datos. Luego, el **decodificador**, que constituye la segunda mitad de la red, reconstruye la salida a partir de esa representación latente.

La arquitectura general de un autocodificador puede representarse de manera esquemática como se muestra en la Figura 2.3. En ella se observa las distintas capas del modelo, desde la entrada hasta la salida reconstruida.




Figura 2.3: Arquitectura de un autocodificador: la entrada X es procesada por el codificador hasta obtener la representación latente Z , a partir de la cual el decodificador reconstruye la salida Y .

Como función de activación en mi autocodificador utilizo GELU debido a sus ventajas frente a la comúnmente empleada ReLU. Entre ellas se destacan: una superficie de pérdida más suave que facilita un entrenamiento más estable y rápido, la ausencia del problema de "neuronas muertas" propio de ReLU y una mayor capacidad de modelar relaciones no lineales gracias a su naturaleza probabilística basada en la distribución normal.

La función $\text{GELU}(x)$ está definida por:

$$\text{GELU}(x) = 0.5 x \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} (x + 0.044715x^3) \right) \right) \quad (2.4)$$

La función $\text{ReLU}(x)$ se define como:

$$\text{ReLU}(x) = \max(0, x) \quad (2.5)$$

Como se muestra en la Figura 2.4, al graficar ambas funciones se puede apreciar la suavidad de **GELU** al aproximarse a 0, en contraste con el comportamiento abrupto de **ReLU**.




Figura 2.4: Comparación entre las funciones de activación ReLU y GELU. Se observa que GELU presenta una transición suave alrededor de cero, lo que evita discontinuidades y favorece un entrenamiento más estable en modelos neuronales.

A partir de esta arquitectura, el autocodificador puede emplearse como un método de **detección de anomalías**. Para ello, el modelo se entrena exclusivamente con la clase que representa el comportamiento normal, es decir, pacientes sin diabetes. Al aprender a reconstruir correctamente este tipo de patrones, cuando el modelo recibe un dato t perteneciente a la misma distribución, se espera que el error de reconstrucción $\|t' - t\|$ sea pequeño.

En contraste, si se presenta un dato atípico t^* , correspondiente a un diagnóstico maligno, el modelo no logra reconstruirlo con la misma fidelidad, generando así un error significativamente mayor. Este comportamiento permite establecer un criterio simple y efectivo para la detección de anomalías: un dato se clasifica como anómalo si su error de reconstrucción supera un umbral ϵ predefinido. El criterio se expresa formalmente en la Ecuación 2.6:

$$\|t^* - t'^*\| > \epsilon \quad (2.6)$$

Donde t'^* es la reconstrucción producida por la red a partir del dato t^* . Si la desigualdad se cumple, el dato se considera *anómalo*; de lo contrario, se clasifica como *normal*.

El valor del umbral ϵ se determinó de manera empírica a partir del conjunto de datos normales utilizado durante el entrenamiento. En particular, se calculó como la **media del error de reconstrucción**. Esta definición se detalla en la Ecuación 2.7:

$$\epsilon = \text{media}(\|t'_i - t_i\|) \quad (2.7)$$

Donde t_i corresponde a cada muestra normal y t'_i a su respectiva reconstrucción generada por el modelo. Este valor promedio proporciona un límite representativo del comportamiento esperado en datos no anómalos, permitiendo distinguir de forma efectiva aquellos casos cuyo error excede significativamente lo aprendido por la red.

2.2.2 Métricas de evaluación del modelo

Para evaluar el rendimiento del autocodificador en la tarea de detección de anomalías, utilizo la **matriz de confusión**, la cual resume la relación entre las predicciones del modelo y las etiquetas reales. En este contexto, cada instancia se clasifica como *normal* o *anómala* según si su error de reconstrucción $\|t' - t\|$

supera o no el umbral ϵ definido, tal como se muestra en la Ecuación 2.8.

$$\hat{y} = \begin{cases} 0, & \text{si } \|t' - t\| \leq \epsilon \\ 1, & \text{si } \|t' - t\| > \epsilon \end{cases} \quad (2.8)$$

A partir de este criterio, se distinguen los siguientes cuatro casos fundamentales:

- **Verdaderos Positivos (TP):** Casos *anómalos* (personas con diabetes) cuyo error de reconstrucción satisface $\|t' - t\| > \epsilon$.
- **Falsos Negativos (FN):** Casos *anómalos* (con diabetes) pero cuyo error cumple $\|t' - t\| \leq \epsilon$, es decir, el modelo no detectó la anomalía.
- **Verdaderos Negativos (TN):** Casos *normales* (sin diabetes) cuyo error satisface $\|t' - t\| \leq \epsilon$.
- **Falsos Positivos (FP):** Casos *normales* (sin diabetes) cuyo error satisface $\|t' - t\| > \epsilon$, siendo incorrectamente clasificados como anómalos.

A partir de estas cuatro categorías se construye la matriz de confusión mostrada en la Tabla ??, donde la diagonal verde representa las predicciones correctas y las celdas rojas los errores de clasificación.

	Predicción	
	Anómalo	Normal
Real: Anómalo	Verdadero Positivo (TP)	Falso Negativo (FN)
Real: Normal	Falso Positivo (FP)	Verdadero Negativo (TN)

Tabla 2.4: Matriz de confusión. La diagonal verde representa predicciones correctas, mientras que las celdas rojas corresponden a errores de clasificación.

Una vez definidas las categorías de la matriz de confusión, es posible cuantificar el rendimiento del modelo mediante distintas métricas, cada una evaluando un aspecto particular de la calidad de las predicciones. Todas ellas se derivan directamente de los valores TP, FP, TN y FN.

La **exactitud** (accuracy) cuantifica la proporción total de predicciones correctas realizadas por el modelo según la Ecuación 2.9.

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{TN} + \text{FN}} \quad (2.9)$$

La precisión (precision) indica qué proporción de las predicciones positivas corresponde realmente a casos positivos, tal como se define en la Ecuación 2.10.

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (2.10)$$

La sensibilidad (recall) mide la capacidad del modelo para identificar correctamente los casos positivos presentes en el conjunto de datos, de acuerdo con la Ecuación 2.11.

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (2.11)$$

La especificidad (specificity) evalúa la proporción de casos negativos correctamente clasificados, definida en la Ecuación 2.12.

$$\text{Specificity} = \frac{\text{TN}}{\text{TN} + \text{FP}} \quad (2.12)$$

La exactitud balanceada (balanced accuracy), mostrada en la Ecuación 2.13, combina sensibilidad y especificidad para obtener una medida equilibrada del rendimiento.

$$\text{Balanced Accuracy} = \frac{\text{Recall} + \text{Specificity}}{2} \quad (2.13)$$

El F1-Score combina las medidas de precisión y sensibilidad para ofrecer una métrica más general de la calidad del modelo, tal como se expresa en la Ecuación 2.14.

$$\text{F1_Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \text{ TP}}{2 \text{ TP} + \text{FP} + \text{FN}} \quad (2.14)$$

En el caso particular de este trabajo, resulta crítico priorizar la métrica de **Recall**. Dado que un falso negativo implica no identificar un caso potencialmente maligno, maximizar el Recall es esencial para garantizar que el modelo no pase por alto ninguna anomalía relevante.

Si bien **Precision** también aporta información valiosa al reducir el número de falsos positivos, la severidad clínica de un falso negativo vuelve al Recall la métrica de mayor importancia práctica en este contexto.

No obstante, para obtener una visión más equilibrada del rendimiento global del sistema, también se considera el **F1_Score**, que combina Recall y Precision en una única medida. De esta manera, aunque el objetivo principal es maximizar el Recall, un F1_Score elevado asegura que dicho incremento no se logra a costa de elevar los falsos positivos, proporcionando así una evaluación más completa de la calidad del modelo.

Chapter 3

Resultados

Mostrar los resultados obtenidos utilizando gráficos, tablas, figuras, etc

En este capítulo se presentan los resultados obtenidos durante el entrenamiento y evaluación del autocodificador propuesto. Para ello, se muestran la configuración utilizada, los histogramas de errores de reconstrucción, las métricas de desempeño para los distintos conjuntos evaluados y finalmente la matriz de confusión porcentual que resume el rendimiento del modelo bajo el criterio definido previamente.

Para entrenar el autocodificador se utilizó la siguiente configuración:




Figura 3.1: Arquitectura del autocodificador utilizado

Los hiperparámetros utilizados durante el entrenamiento se listan en la Tabla 3.1:

Parámetro	Modelo A	Modelo B	Modelo C
Tasa de aprendizaje (lr)	0.001	0.001	0.001
Tamaño de batch (batch size)	32	32	32
Épocas de entrenamiento	50	50	50
Función de pérdida	MSE	MSE	MSE
Optimizador	Adam	Adam	Adam

Tabla 3.1: Hiperparámetros de entrenamiento empleados para los modelos A, B y C, entrenados con los correspondientes conjuntos.

Para cada uno de los modelos entrenados (A, B y C) calculé el umbral ϵ que permite distinguir entre instancias normales y anómalas a partir del error de reconstrucción. Dicho umbral se obtiene utilizando únicamente el conjunto de entrenamiento, siguiendo el criterio definido en la Ecuación 2.7. Los valores finales de empleados por cada modelo se muestran en la Tabla 3.2.

Parámetro	Modelo A	Modelo B	Modelo C
Umbral ϵ	0.XXX	0.YYY	0.ZZZ

Tabla 3.2: Valores de umbral ϵ obtenidos para los modelos A, B y C.

Una vez establecido el umbral para cada modelo, analicé la distribución del error de reconstrucción sobre el conjunto de prueba. Los histogramas correspondientes, presentados en las Figuras 3.2, 3.3 y 3.4 permiten visualizar cómo se distribuyen los errores y cómo se posiciona el umbral ϵ en cada caso. Esta comparación facilita interpretar la capacidad del autocodificador para separar registros normales de anómalos según su desempeño con distintos niveles de contaminación en el entrenamiento.




Figura 3.2: Distribución del error de reconstrucción para el Modelo A.




Figura 3.3: Distribución del error de reconstrucción para el Modelo B.




Figura 3.4: Distribución del error de reconstrucción para el Modelo C.

Explicación...




Figura 3.5: Matriz de confusión expresada en valores porcentuales para el conjunto evaluado.

Finalmente, se obtuvieron las métricas de la Tabla 3.3 donde se puede observar ...

Explicación...

Métrica	Conjunto A (0% Anómalos)	Conjunto B (10% Anómalos)	Conjunto C (25% Anómalos)
<i>Accuracy</i>	0.7193	—	—
<i>Precision</i>	0.5735	—	—
<i>Recall</i>	0.9286	—	—
<i>Specificity</i>	0.5972	—	—
<i>Balanced Accuracy</i>	0.7629	—	—
<i>F1_Score</i>	0.7091	—	—

Tabla 3.3: Métricas de rendimiento del modelo evaluado sobre el mismo conjunto de prueba para los conjuntos A, B y C. Cada conjunto fue entrenado con distinta proporción de datos anómalos, lo que permite analizar la robustez del autocodificador frente a diferentes niveles de contaminación en el entrenamiento.

Explicación...

CURVA ROC

Chapter 4

Conclusiones

Explicar que aprendimos con la realización de este trabajo. Qué nos muestran los resultados.

Bibliography

- [1] R Bouman and T Heskes. Autoencoders for anomaly detection are unreliable. *arXiv preprint arXiv:2501.13864*, 2025.
- [2] Aristidis Diamantis, Emmanouil Magiorkinis, and Helen Koutselini. Fine-needle aspiration (fna) biopsy: historical aspects. *Folia histochemica et cytobiologica*, 47(2):191–197, 2009.
- [3] UCI Machine Learning and Ovsen. Breast cancer wisconsin (diagnostic) data set. <https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data>. Kaggle Dataset. Accedido: 2025-11-27.
- [4] A A Nelay and M Turgeon. A comprehensive study of auto-encoders for anomaly detection: Efficiency and trade-offs. *Machine Learning with Applications*, 17:100572, 2024.
- [5] T Walczyna et al. Enhancing anomaly detection through latent space manipulation. *Applied Sciences*, 15(1):286, 2025.
- [6] William Wolberg, Olvi Mangasarian, Nick Street, and W. Street. Breast cancer wisconsin (diagnostic). UCI Machine Learning Repository, 1993. DOI: <https://doi.org/10.24432/C5DW2B>.